

ESPECIALIZACIÓN EN BUSINESS INTELLIGENCE & BUSINESS ANALYTICS

Módulo: Calidad de Datos y Analítica Avanzada

CASO DE ESTUDIO

Calidad de Atención Hospitalaria y Factores Socioeconómicos en EE.UU.

Un proyecto de analítica avanzada para la identificación de hospitales en riesgo

Nivel	Intermedio – Avanzado
Duración estimada	40–60 horas de trabajo práctico
Herramientas	Python · pandas · scikit-learn · matplotlib · seaborn · Jupyter
Fuentes de datos	CMS Provider Data (EE.UU.) · County Health Rankings
Tema central	Calidad de datos, integración, modelado predictivo y clustering

1. Introducción

El sistema de salud de los Estados Unidos invierte más de 4 billones de dólares anuales, pero la calidad de atención varía dramáticamente entre hospitales y regiones. Esta variación no es aleatoria: está correlacionada con factores operacionales del hospital y con el contexto socioeconómico del entorno donde opera.

Este caso de estudio simula el trabajo de una consultora de analítica de salud contratada por un Departamento de Salud estatal. Su encargo es identificar qué hospitales tienen mayor riesgo de baja calidad de atención, y qué factores —tanto internos como del entorno— mejor explican ese riesgo. El análisis no busca castigar instituciones, sino generar evidencia para focalizar recursos e intervenciones donde más se necesitan.

A lo largo de este laboratorio, el estudiante recorrerá todo el ciclo analítico profesional: desde la ingesta de datos en múltiples formatos hasta la interpretación de modelos para ejecutivos, pasando por perfilado, limpieza, tratamiento de valores faltantes y outliers, feature engineering y modelado predictivo. Cada decisión técnica deberá justificarse con criterios metodológicos y de negocio. Esa justificación es el núcleo del aprendizaje.

2. Objetivos del Caso

2.1 Objetivo General

Desarrollar un análisis completo del ciclo de datos que integre múltiples fuentes heterogéneas para identificar factores predictivos de baja calidad hospitalaria y segmentar hospitales según su perfil de riesgo, produciendo recomendaciones accionables para política pública.

2.2 Objetivos Específicos

- Ingestar y diagnosticar la calidad de cuatro datasets provenientes de fuentes distintas y en formatos diferentes.
- Aplicar un proceso de 9 pasos para el tratamiento de valores faltantes: diagnóstico con 4 tests estadísticos (Little MCAR, análisis de patrones, correlación entre indicadores, Kolmogorov-Smirnov), comparación de 4 métodos de imputación (Media, Mediana, KNN, MICE) con métricas de calidad, y aplicación del mejor método según score de preservación de distribución.
- Detectar y gestionar outliers distinguiendo errores de captura de información valiosa.
- Diseñar índices compuestos (HospitalQualityIndex, SocioeconomicVulnerabilityIndex) con lógica de negocio justificada.
- Comunicar resultados técnicos en lenguaje ejecutivo, documentando limitaciones y supuestos.

3. Contexto del Negocio

3.1 El Problema

El Departamento de Salud de un estado ha identificado que sus tasas de readmisión hospitalaria son un 15% superiores al promedio nacional. Este indicador es crítico: cada readmisión innecesaria cuesta en promedio USD 15,000 y es penalizada por Medicare. Las encuestas de satisfacción del paciente muestran alta variabilidad entre hospitales del mismo estado, sin una explicación clara.

La hipótesis de trabajo es que la calidad de atención no depende únicamente de la gestión interna del hospital, sino también del contexto socioeconómico del condado donde opera. Un hospital en un condado con alta pobreza, bajo acceso a médicos y alta proporción de pacientes sin seguro enfrenta condiciones estructuralmente distintas a uno ubicado en un condado rico y con alta cobertura médica.

3.2 Stakeholders

Stakeholder	Rol e Interés en el Análisis
Director de Salud del Estado	Necesita un ranking de hospitales con riesgo y recomendaciones accionables de política pública.
Administradores hospitalarios	Quieren benchmarks comparativos con hospitales similares en contexto y tipo.
CMS / Medicare	Usa los datos de calidad para definir reembolsos y penalizaciones económicas.
Equipo de Data Science	Responsable de la integridad técnica, reproducibilidad y documentación del análisis.
Pacientes y comunidades	Afectados directamente por las decisiones de política que deriven del análisis.

3.3 Riesgos del Proyecto

- Sesgo de selección: hospitales pequeños reportan menos métricas, lo que puede hacerlos parecer de menor riesgo.
- Confusión causal: atribuir mala calidad al hospital cuando el factor determinante es el contexto socioeconómico.
- Granularidad: mezclar datos a nivel hospital con datos a nivel condado sin documentar las implicaciones estadísticas.
- Temporalidad: los datasets tienen distintos años de referencia, lo que puede introducir inconsistencias sistemáticas.

4. Pregunta Analítica Central

Pregunta Analítica Central
¿Qué combinación de factores operacionales del hospital y socioeconómicos del condado
predice mejor la probabilidad de que un hospital tenga una tasa de readmisión elevada
y una baja satisfacción del paciente, y qué segmentos de hospitales emergen de ese patrón?

Esta pregunta fue diseñada para cumplir cuatro criterios metodológicos:

- Requiere integración de múltiples fuentes: datos hospitalarios de CMS (3 datasets) y datos socioeconómicos por condado.
 - Puede responderse mediante evidencia cuantitativa: tasas de readmisión, puntajes de satisfacción e indicadores socioeconómicos son medibles.
 - Permite análisis descriptivo (cómo se distribuyen los indicadores) y explicativo (qué variables predicen la calidad).
 - Tiene relevancia directa para el negocio: se traduce en decisiones de política, asignación de recursos y sistema de incentivos.
-

5. Descripción de los Datasets

El análisis integra cuatro fuentes de datos públicas y verificables. Todas son accesibles sin registro previo y representan el tipo de fuentes que un Data Analyst o Data Scientist encontraría en un proyecto real de salud pública.

Dataset 1: Hospital General Information (CMS)

Atributo	Detalle
Fuente	Centers for Medicare & Medicaid Services (CMS)
URL	https://data.cms.gov/provider-data/dataset/xubh-q36u
Formato	CSV (aprox. 5,000 filas x 28 columnas)
Nivel de agregación	Hospital (una fila = un hospital)
Clave primaria	Facility ID (codigo alfanumerico de 6 caracteres)

Variables principales: Facility ID, Facility Name, State, City, ZIP Code, County Name, Hospital Type, Hospital Ownership, Emergency Services, Hospital overall rating.

Problemas reales de calidad de datos

- Hospital overall rating contiene el string "Not Available" en lugar de NULL, haciendo que pandas lea la columna como texto. Los analisis estadisticos fallan silenciosamente si no se detecta.
- County Name tiene inconsistencias de mayusculas/minusculas que impiden el join con el Dataset 4.
- ZIP Code tiene codigos de 4 digitos para hospitales de Connecticut (Excel elimino el cero inicial).
- Hay hospitales duplicados con el mismo nombre pero diferente Facility ID por fusiones no depuradas.

Dataset 2: HCAHPS — Encuesta de Satisfaccion del Paciente

Atributo	Detalle
Fuente	CMS — Hospital Consumer Assessment of Healthcare Providers
URL	https://data.cms.gov/provider-data/dataset/dgck-syfz
Formato	CSV en formato largo (aprox. 100,000 filas)
Nivel de agregacion	Hospital x Metrica de satisfaccion
Clave foranea	Facility ID (conecta con Dataset 1)

El dataset esta en formato largo (tall format): cada hospital tiene multiples filas, una por cada metrica. Para el analisis debe pivotearse a formato ancho.

Problemas reales de calidad de datos

- HCAHPS Answer Percent contiene "Not Applicable", "Not Available" y "*" (privacidad por bajo volumen). Estos tres strings representan mecanismos de missing distintos.
- La tasa de respuesta puede ser 0% o mayor al 100% por errores de captura, valores imposibles.
- El periodo de referencia varia entre hospitales, generando inconsistencias temporales.

Dataset 3: Readmissions and Deaths (CMS)

Atributo	Detalle
Fuente	CMS Provider Data — Complications and Deaths
URL	https://data.cms.gov/provider-data/dataset/9n3s-kdb3
Formato	CSV en formato largo (aprox. 100,000 filas)
Nivel de agregacion	Hospital x Medida de readmision
Clave foranea	Facility ID

Problemas reales de calidad de datos

- Score viene como string con variaciones de capitalizacion en "Not Available" que requieren limpieza con expresiones regulares.
- Denominadores bajos (< 25 casos) generan tasas estadisticamente inestables que parecen outliers pero son informacion real.
- La columna "Compared to National" tiene missings MAR: faltan cuando el denominador es muy bajo para calcular significancia. El Test 1 (Little) confirma dependencia con "Number of Discharges". Estrategia: imputar con KNNImputer usando denominador como predictor, no con media global.

Dataset 4: County Health Rankings (Robert Wood Johnson Foundation)

Atributo	Detalle
Fuente	Robert Wood Johnson Foundation / University of Wisconsin
URL	https://www.countyhealthrankings.org/sites/default/files/media/document/analytic_data2025_v3.csv
Formato	Excel (.xlsx) con multiples pestanas
Nivel de agregacion	Condado (una fila = un condado de EE.UU.)
Clave	FIPS + State + County Name (join por State+County normalizado)

Variables: % Adults with obesity, % Smokers, Median household income, % Uninsured, Primary care physicians rate, % Children in poverty, High school graduation rate.

Problemas reales de calidad de datos

- El archivo Excel tiene multiples pestanas; pandas carga la primera por default, que puede ser la leyenda y no los datos.
- County Name NO incluye la palabra "County" en este dataset, pero si en el Dataset 1 — el join directo produce un DataFrame vacio.
- Median household income viene con comas como separadores de miles, haciendo que pandas lo lea como string.
- El ano de referencia varia por indicador (2021–2022 vs datos hospitalarios 2023): desfase temporal documentable.

6. Esquema de Integracion de Datos

La tabla maestra resultante tendra una fila por hospital y consolidara variables de los cuatro datasets. El proceso de integracion sigue tres pasos secuenciales:

1. Pivotar D2 y D3 de formato largo a formato ancho (una fila por hospital, cada metrica en su propia columna).
2. Hacer LEFT JOIN de D1 con D2 y D3 usando Facility ID como clave. Esto preserva todos los hospitales aunque no tengan metricas de satisfaccion.
3. Normalizar nombres de condados (minusculas, eliminar sufijo "county", eliminar espacios) y hacer LEFT JOIN con D4 por State + County normalizado.

Resultado: una tabla maestra con una fila por hospital que incluye características operacionales, metricas de satisfaccion, tasas de readmision e indicadores socioeconomicos del condado.

Problema de Join	Estrategia de resolucion
Formato largo de D2 y D3	Pivotar a ancho antes del join para evitar producto cartesiano.
Nombres de condados inconsistentes	Normalizar ambas fuentes: minusculas, sin sufijo "county", sin espacios.
Hospitales sin match en D4	Imputar con mediana del estado; documentar como limitacion.
Granularidad hospital vs condado	Aceptar que multiples hospitales heredan el mismo valor de condado; controlar en el modelado.

7. Actividades del Laboratorio

Cada parte del laboratorio tiene un objetivo especifico de aprendizaje. No son simplemente "pasos a seguir": cada una busca desarrollar un razonamiento particular sobre los datos. El codigo esta en el notebook Jupyter adjunto.

Parte 1 — Ingesta de Datos

Objetivo: cargar los cuatro datasets detectando y resolviendo problemas de formato antes de cualquier analisis. La ingesta correcta es el prerequisite de todo lo demas: datos mal cargados producen analisis incorrectos sin que el analista se de cuenta.

- Cargar D1 (CSV) con encoding="utf-8-sig" para manejar el BOM invisible y dtype=str para preservar ceros en ZIP Codes.
- Cargar D4 (Excel) especificando sheet_name correcto y skiprows para saltar filas de encabezado adicionales.
- Cargar D2 y D3 (CSV formato largo) y verificar que Facility ID aparece el numero esperado de veces.
- Documentar: dimensiones, encoding y anomalias detectadas en cada dataset.

Parte 2 — Perfilado de Datos

Objetivo: entender la estructura, cardinalidad y calidad superficial de cada dataset antes de modificarlo. El perfilado es el diagnostico medico de los datos: sin el, cualquier tratamiento es a ciegas.

- Calcular dimensiones, tipos de datos y porcentaje de nulos para cada dataset.
- Verificar unicidad de la clave primaria: Facility ID debe ser unico en Dataset 1.
- Analizar cardinalidad de variables categoricas: si Hospital Ownership tiene 47 valores unicos cuando se esperaban 5, hay un problema de normalizacion.
- Identificar dominios validos: calificacion entre 1 y 5, tasas de readmision entre 0 y 100.

Parte 3 — Calidad de Datos

Objetivo: evaluar las cinco dimensiones de calidad y documentar decisiones de tratamiento justificadas. La clave es que cada decision debe tener una justificacion: ¿por que eliminar? ¿por que corregir? ¿por que documentar y continuar?

Dimension	Que evaluar en este caso
Compleitud	¿Que porcentaje de hospitales tiene la calificacion general? ¿Cuales metricas tienen mas del 30% de nulos?
Exactitud	¿Hay tasas de readmision mayores al 100%? ¿Tasas de respuesta menores a 0%?
Consistencia	¿El periodo de referencia de D2 y D3 es coherente para el mismo hospital?
Unicidad	¿Facility ID es unico en D1? ¿Hay filas completamente duplicadas?
Validez	¿Los codigos de estado son validos? ¿Los tipos de hospital pertenecen al dominio esperado?

Parte 4 — Diagnóstico y Tratamiento de Valores Faltantes

Objetivo: diagnosticar el mecanismo de ausencia de cada variable con evidencia estadística (4 tests) y aplicar la estrategia de imputación más adecuada comparando 4 métodos. La secuencia metodológica es: (1) tabla resumen de nulos, (2) visualización de patrones con missingno, (3–6) cuatro tests estadísticos, (7) diagnóstico integrado, (8) comparación de métodos de imputación con métricas de calidad, y (9) aplicación del mejor método validando que se preserve la distribución original.

- MCAR (Missing Completely At Random): el dato falta totalmente al azar, sin relación con ninguna otra variable. Test: comparar medias entre grupos con y sin missing (Little's test). Cualquier método de imputación es válido.
- MAR (Missing At Random): el dato falta por razones relacionadas con otras variables observadas. Ejemplo: hospitales Critical Access no tienen rating CMS porque el tipo de hospital predice la ausencia. Métodos recomendados: KNNImputer o MICE (IterativeImputer).
- MNAR (Missing Not At Random): el dato falta por razones relacionadas con el propio valor ausente. Ejemplo: hospitales de baja calidad omiten voluntariamente ciertos reportes. La imputación ingenua introduce sesgo; se debe documentar y considerar modelos de selección.

El laboratorio aplica el siguiente proceso de 9 pasos para la variable "Hospital overall rating" (mayor porcentaje de nulos en D1) y las variables socioeconómicas de D4:

Secuencia metodológica de 9 pasos (implementada en el notebook):

Paso 1 — Tabla resumen de nulos: número de missings, porcentaje, y registros completos por variable, ordenados de mayor a menor porcentaje.

Paso 2 — Visualización de patrones: `missingno.matrix()` y `missingno.heatmap()` para identificar visualmente si los nulos aparecen de forma aleatoria o agrupada.

Paso 3 — Test 1: Aproximación al test de Little (MCAR). Para cada variable con nulos, comparar la media de otras variables numéricas entre el grupo con datos ausentes y el grupo con datos presentes (t-test de Welch). Si más del 20% de comparaciones resultan significativas ($p < 0.05$) → NO MCAR.

Paso 4 — Test 2: Análisis de patrones de missing. Contar combinaciones únicas de variables faltantes (`df.isnull().value_counts()`). Más de 100 patrones únicos → alta diversidad → MAR o MNAR. Pocos patrones → compatible con MCAR.

Paso 5 — Test 3: Correlación entre indicadores de missing. Construir una matriz binaria de indicadores de nulos (0/1) y calcular su correlación. $|r| > 0.3$ entre dos variables → sus ausencias ocurren de forma sistemática → MAR o MNAR. Visualizar con heatmap de correlaciones.

Paso 6 — Test 4: Kolmogorov-Smirnov (KS). Comparar la distribución de variables continuas entre el grupo donde otra variable tiene missings vs. donde está completa. $p < 0.05$ → distribuciones diferentes → MAR o MNAR. Visualizar con histogramas superpuestos de los dos grupos.

Paso 7 — Diagnóstico integrado: cruzar los resultados de los 4 tests para asignar un mecanismo final (MCAR / MAR / MNAR) a cada variable y justificar la elección del método de imputación.

Paso 8 — Comparación de 4 métodos de imputación: evaluar Media (`SimpleImputer`), Mediana (`SimpleImputer`), KNNImputer ($k=5$) y MICE (`IterativeImputer`, `max_iter=10`). Métricas de calidad: diferencia absoluta de media y desviación estándar respecto al dataset original. Seleccionar el método con menor score combinado. Visualizar con gráfico de 4 paneles: distribuciones, boxplot comparativo y barras de preservación de media/std.

Paso 9 — Imputación final y validación visual: aplicar el método seleccionado, verificar que los nulos son cero y comparar histogramas antes/después. Para D4 usar imputación por mediana del estado.

Parte 5 — Outliers

Objetivo: detectar valores extremos y decidir su tratamiento distinguiendo errores de información valiosa. Nunca se elimina un outlier por el simple hecho de serlo; primero se investiga su causa.

- Aplicar IQR, Z-score e Isolation Forest. Comparar resultados entre métodos y explicar discrepancias.
- Para cada outlier identificado: ¿es un error de captura o información real sobre un caso extremo? Justificar la decisión.

- Estrategias disponibles: eliminacion, winsurizacion, cap por criterio de dominio, log-transformacion, mantener y documentar.

Parte 6 — Transformaciones

Objetivo: preparar variables para el modelado aplicando la transformacion correcta para cada tipo y distribucion.

Variable	Transformacion y justificacion
Median household income	Log Transform: distribucion muy asimetrica con cola derecha larga.
Tasa de readmision	RobustScaler: presencia de outliers legitimos (hospitales con bajo volumen).
Calificacion general (1-5)	MinMaxScaler: escala con significado absoluto y sin outliers extremos.
Hospital Ownership	One-Hot Encoding: variable nominal sin orden intrinseco.
Hospital Type	One-Hot Encoding: agrupar tipos con < 2% de frecuencia en "Other".

Parte 7 — Feature Engineering

Objetivo: construir indicadores compuestos que capturen dimensiones latentes que ninguna variable individual representa por si sola. Este es el momento donde el analista aplica su conocimiento del dominio.

HospitalQualityIndex (HQI): combina satisfaccion normalizada (peso 0.4), readmision inversa normalizada (0.4) y calificacion general (0.2). La readmision se invierte porque a menor readmision, mayor calidad.

SocioeconomicVulnerabilityIndex (SVI): combina porcentaje sin seguro medico (0.35), porcentaje en pobreza (0.35) e inversa de la tasa de medicos primarios (0.30).

Variables adicionales: PatientVolumeCategory (Bajo/Medio/Alto segun denominador de readmisiones) y RuralFlag (1 si es Critical Access Hospital).

Parte 8 — Analisis Exploratorio (EDA)

Objetivo: descubrir patrones, distribuciones y relaciones antes del modelado. El EDA valida las hipotesis del proyecto y guia la seleccion de variables.

- Distribucion del HQI: ¿es bimodal? ¿Sugiere grupos naturales?
- Correlacion entre SVI y HQI: ¿el contexto adverso se asocia con menor calidad? ¿La relacion es lineal?
- Boxplot de HQI por Hospital Ownership y Hospital Type: ¿hay diferencias estadisticamente significativas?
- Mapa de calor de correlaciones: ¿que variables del Dataset 4 correlacionan mas con la calidad hospitalaria?

Parte 9 — Modelado Analitico

Objetivo: construir modelos que respondan la pregunta analitica con rigor metodologico y explicabilidad para el negocio.

Modelo 1 — XGBoost (clasificación): crear variable binaria `low_quality=1` si HQI está en el cuartil inferior. Entrenar, evaluar con AUC-ROC y extraer feature importance. ¿Que factores predicen mejor la baja calidad?

Modelo 2 — K-Means (clustering): segmentar hospitales en el espacio {HQI, SVI}. Determinar K óptimo con Silhouette Score. Perfilar cada cluster e interpretarlo en términos de negocio.

Modelo 3 — Random Forest (validación): correr en paralelo con XGBoost. Si ambos coinciden en las variables más importantes, la conclusión es robusta.

Parte 10 — Interpretación para el Negocio

Objetivo: traducir hallazgos técnicos en conclusiones accionables para el Director del Departamento de Salud. Esta etapa no es opcional: un análisis sin interpretación de negocio es un ejercicio técnico sin valor.

Redactar un informe ejecutivo (máximo 2 páginas) que responda la pregunta analítica, presente los segmentos de hospitales y proponga recomendaciones diferenciadas por segmento.

8. Preguntas de Reflexion y Pensamiento Critico

Las siguientes preguntas no tienen una unica respuesta correcta. Se evalua la calidad del razonamiento, la evidencia utilizada y la coherencia de la justificacion. Evita respuestas de una linea.

4. El Dataset 4 tiene datos socioeconomicos del 2021, pero los datos hospitalarios son del 2023. ¿En que condiciones este desfase temporal introduce sesgo? ¿Cuando seria aceptable ignorarlo y cuando no?
5. 2. Aplicaste los 4 tests de diagnóstico y concluiste MAR. Tu compañero argumenta que los hospitales de baja calidad omiten voluntariamente sus reportes (MNAR). ¿Qué evidencia adicional buscarías para distinguir MAR de MNAR? ¿Cómo cambiaría tu estrategia de imputación si la evidencia apuntara a MNAR?
6. Al hacer el join hospital-condado, multiples hospitales heredan los mismos valores socioeconomicos. ¿Que problema estadistico genera esto en el modelado? ¿Como lo controlarías?
7. Encontraste un hospital con tasa de readmision del 60% (outlier extremo). Al investigar, es un hospital de 8 camas en area rural. ¿Lo eliminas, winsurizas o mantienes? Justifica considerando el impacto en el HQL.
8. Usaste One-Hot Encoding para State (50 estados), anadiendo 49 columnas. ¿Que problema introduce en una regresion logistica? ¿Que alternativa usarias y por que?
9. Asignaste pesos 0.4/0.4/0.2 al HQL. Un stakeholder pregunta: ¿por que satisfaccion y readmision pesan lo mismo? ¿Que metodo mas riguroso podrias usar para definir pesos?
10. Tu XGBoost alcanzo $AUC = 0.82$. El director quiere implementarlo para decisiones de auditoria. ¿Que le dirias antes de autorizar ese uso? ¿Que informacion adicional necesitas?
11. La variable mas importante del modelo es PatientVolumeCategory. ¿Significa que el volumen CAUSA mala calidad? ¿Como distingues correlacion de causalidad en este analisis?
12. Eliminaste hospitales de veteranos (VA) porque no reportan metricas de CMS. ¿Que sesgo introduces? ¿A que conclusiones erroneas puede llevar esto si el director generaliza los resultados?
13. El hospital con el peor HQL del estado opera en el condado mas vulnerable. El gobernador quiere sancionarlo publicamente. ¿Que argumentos presentarias a favor y en contra, basados en el analisis?

Apéndice A — Diccionario de Datos

Este apéndice describe cada variable de los cuatro datasets utilizados en el caso de estudio. Para cada campo se indica: nombre original del archivo CSV, tipo de dato inferido, porcentaje de valores nulos, valores posibles o rango, y descripción funcional. Las advertencias de calidad (⚠) señalan variables que requieren tratamiento especial antes de cualquier análisis.

D1 — Hospital General Information (CMS) | 38 variables | ~5,000 hospitales

Unidad de análisis: hospital (una fila por Facility ID). Fuente: data.cms.gov. Actualización: anual. Clave primaria: Facility ID (código numérico de 6 dígitos asignado por CMS).

Variable	Tipo	Descripción
Facility ID	Texto/Num	Identificador único CMS del hospital. Clave primaria del dataset y del JOIN con D2 y D3. ⚠ Viene como string con cero inicial; si se convierte a int se pierde el cero.
Facility Name	Texto	Nombre oficial del hospital. No usar como clave de join (variaciones de ortografía).
Address	Texto	Dirección física. Solo uso descriptivo.
City/Town	Texto	Ciudad donde opera el hospital.
State	Categorico	Abreviatura de estado (2 letras). Usada en JOIN con D4 como clave secundaria.
ZIP Code	Texto	⚠ Connecticut tiene códigos de 4 dígitos porque Excel eliminó el cero inicial. Leer como dtype=str.
County/Parish	Texto	⚠ Inconsistencias de mayúsculas y sufijo "County" vs. sin sufijo impiden el join directo con D4. Normalizar con strip().upper() y eliminar la palabra COUNTY.
Telephone Number	Texto	Teléfono de contacto. No se utiliza en el análisis.
Hospital Type	Categorico	Tipo de hospital según clasificación CMS. Variable clave: los Critical Access Hospitals (CAH) no tienen rating, lo que explica el mecanismo MAR de valores faltantes en esa columna.
Hospital Ownership	Categorico	Tipo de propiedad del hospital. Variable de control para análisis de diferencias de calidad.
Emergency Services	Binario	Indica si el hospital ofrece servicio de emergencias. Convertir a 0/1 para modelado.
Meets criteria for birthing friendly	Binario	⚠ 58.3% de nulos. Los hospitales sin unidad obstétrica no aplican (MAR). No imputar.
Hospital overall rating	Ordinal	⚠⚠ Variable objetivo principal del análisis. "Not Available" debe reemplazarse por NaN antes de convertir a numérico. El mecanismo es MAR: los Critical Access Hospitals no reciben rating CMS. Imputar con KNNImputer usando Hospital Type como predictor.
Hospital overall rating footnote	Categorico	Explica por qué falta el rating. Útil para confirmar el mecanismo MAR. No imputar.
MORT Group Measure Count	Numerico	Número de medidas de mortalidad evaluadas para este hospital.
Count of Facility MORT Measures	Numerico	Cuántas medidas de mortalidad tiene el hospital disponibles.
Count of MORT Measures Better	Numerico	Medidas de mortalidad donde el hospital está MEJOR que el promedio nacional.
Count of MORT Measures No Different	Numerico	Medidas de mortalidad sin diferencia significativa del promedio nacional.
Count of MORT Measures Worse	Numerico	Medidas de mortalidad donde el hospital está PEOR que el promedio nacional.
MORT Group Footnote	Categorico	Nota sobre la evaluación de mortalidad. Alta proporción de nulos.
Count of Safety Measures Better	Numerico	Medidas de seguridad del paciente donde el hospital supera el promedio nacional.
Count of Safety Measures Worse	Numerico	Medidas de seguridad del paciente donde el hospital está por debajo del promedio.
Safety Group Footnote	Categorico	⚠ 68% de nulos; solo aplica a hospitales con evaluación de seguridad disponible.
Count of READM	Numerico	Medidas de readmisión donde el hospital supera el promedio nacional.

Measures Better		
Count of READM Measures Worse	Numerico	Medidas de readmisión donde el hospital está por debajo del promedio.
READM Group Footnote	Categorico	⚠ 81.6% de nulos. Solo aplica a hospitales con métricas de readmisión.
Count of Facility Pt Exp Measures	Categorico	Número de métricas de experiencia del paciente disponibles para este hospital.
Pt Exp Group Footnote	Categorico	⚠ 71.2% de nulos.
Count of Facility TE Measures	Numerico	Número de métricas de eficiencia del tratamiento disponibles.
TE Group Footnote	Categorico	⚠ 84.6% de nulos — el grupo de eficiencia es el menos reportado.

D2 — HCAHPS: Hospital Consumer Assessment of Healthcare Providers | 22 variables | Formato LARGO

Unidad de análisis: hospital × métrica HCAHPS (una fila por cada combinación). Un mismo hospital tiene ~68 filas (una por cada pregunta de la encuesta). Clave de join: Facility ID. Requiere pivotear a formato ancho antes del análisis.

Variable	Tipo	Descripción
Facility ID	Texto/Num	Clave de join con D1 y D3. Aparece repetida ~68 veces por hospital (una por métrica).
Facility Name	Texto	Redundante con D1. No usar como clave.
State	Categorico	Estado del hospital.
HCAHPS Measure ID	Categorico	Identificador de la métrica HCAHPS. Variable de pivot: se convierte en nombre de columna al pasar a formato ancho. Hay 68 métricas distintas. Las más relevantes para el HQI: H_COMP_1 (comunicación médicos), H_COMP_2 (comunicación enfermeras), H_CLEAN_HSP (limpieza), H_QUIET_HSP (ruido).
HCAHPS Question	Texto	Texto completo de la pregunta de la encuesta. Uso descriptivo para etiquetas en gráficos.
HCAHPS Answer Description	Texto	Descripción de la categoría de respuesta evaluada en esta fila.
Patient Survey Star Rating	Ordinal	⚠ "Not Applicable" es un string, no un nulo real. Reemplazar por NaN antes de convertir a numérico.
HCAHPS Answer Percent	Numerico	⚠⚠ Variable de análisis principal. Contiene 3 tipos de valores problemáticos: (1) "Not Available" = nulo real; (2) "*" = privacidad por bajo volumen (<11 respuestas); (3) valores fuera de rango (0% o >100%). Todos deben convertirse a NaN antes de pd.to_numeric().
HCAHPS Linear Mean Value	Numerico	Media lineal de la métrica. Alternativa al porcentaje para algunas métricas. Solo aplica a ciertas dimensiones.
Number of Completed Surveys	Numerico	Número de encuestas completadas. Denominador base. ⚠ Valores bajos (<100) hacen la estimación estadísticamente inestable.
Survey Response Rate Percent	Numerico	⚠ Puede ser 0% (no hay respuestas) o superior al 100% por errores de captura. Validar rango [5%, 100%].
Start Date / End Date	Fecha	Período de referencia de la encuesta. El dataset cubre julio 2024 – junio 2025. ⚠ El periodo de referencia puede variar entre hospitales.

D3 — Hospital Readmissions Reduction Program (HRRP / FY 2026) | 12 variables | Formato LARGO

Unidad de análisis: hospital × condición clínica (6 condiciones por hospital). Clave de join: Facility ID. Período de referencia: julio 2021 – junio 2024. Fuente: data.cms.gov/provider-data.

Variable	Tipo	Descripción
Facility ID	Texto/Num	Clave de join con D1 y D2.
Facility Name	Texto	Redundante con D1.
State	Categorico	Estado del hospital.
Measure Name	Categorico	6 condiciones clínicas: reemplazo de cadera/rodilla, cirugía cardíaca, COPD, insuficiencia cardíaca, neumonía, infarto agudo de miocardio.

Number of Discharges	Numerico	△△ 65% de nulos. Faltan cuando el denominador es demasiado bajo para calcular la tasa. Mecanismo MAR: los hospitales pequeños tienen denominadores bajos para condiciones específicas. Los valores bajos (<25) generan tasas estadísticamente inestables que aparecen como outliers extremos.
Excess Readmission Ratio (ERR)	Numerico	△△ Variable clave del análisis. ERR > 1.0 = más readmisiones que lo esperado (penalizado). ERR < 1.0 = menos readmisiones. 45% de nulos por denominadores bajos. △ Outliers extremos (ERR > 2.0) son hospitales rurales con muy pocos casos: real pero estadísticamente inestable. Tratar con winsorización P1-P99, no eliminar.
Predicted Readmission Rate	Numerico	Tasa de readmisión predicha para este hospital dado su mix de pacientes.
Expected Readmission Rate	Numerico	Tasa de readmisión esperada si el hospital tuviera calidad promedio nacional dado su mix de pacientes.
Number of Readmissions	Numerico	△ "Too Few to Report" es un string informativo, no un nulo. Indica que hay <11 readmisiones — confidencialidad. Reemplazar por NaN antes del análisis numérico.
Footnote	Categorico	Explica por qué una celda está vacía o tiene valor inusual. Usar para confirmar mecanismo MAR.
Start Date / End Date	Fecha	Período de 3 años para cálculo de tasas. Mismo para todos los hospitales en este archivo.

ERR = Excess Readmission Ratio. ERR > 1.0 implica penalización económica para el hospital. Hospitales CAH (Critical Access) están exentos del programa HRRP → siempre tendrán nulos en este dataset.

D4 — County Health Rankings & Roadmaps 2025 (RWJF) | 796 variables totales | ~3,200 condados

Unidad de análisis: condado (una fila por FIPS Code). Fuente: Robert Wood Johnson Foundation. El dataset completo tiene 796 columnas (valor, numerador, denominador, IC bajo/alto, flag por raza y etnia). Para este caso se utilizan 7 variables de "raw value" (valor directo). Clave de join: State Abbreviation + County Name (normalizado).

Variable (raw value)	Tipo	Descripción
5-digit FIPS Code	Texto	Clave geográfica federal única por condado. Estado (2 dígitos) + condado (3 dígitos). △ Leer como string para preservar ceros iniciales.
State Abbreviation	Texto	Primera clave del join con D1. △ El dataset también incluye filas de nivel estatal (State Abbreviation sin código de condado) y la fila nacional (US). Filtrar antes del join.
Name	Texto	△ Siempre incluye la palabra "County", "Parish", "Borough" o "Census Area" — a diferencia de D1 que a veces la omite. Normalizar eliminando estos sufijos antes del join.
Primary Care Physicians raw value	Número	Número de médicos de atención primaria por habitante del condado. Valores altos indican mayor acceso a la salud. △ Viene en formato decimal (no por 1,000 habitantes). Multiplicar por 100,000 para mayor legibilidad.
Uninsured Adults raw value	Número	Porcentaje de adultos sin seguro médico en el condado. Mayor valor = mayor vulnerabilidad. Variable principal del SVI.
Children in Poverty raw value	Número	Porcentaje de niños en situación de pobreza. Indicador de vulnerabilidad socioeconómica a largo plazo.
Median Household Income raw value	Número	△ Viene como número sin comas (no como string con coma de miles en la versión CSV). Verificar que pandas lo lea correctamente como numérico. Correlaciona inversamente con el SVI.
Adult Obesity raw value	Número	Porcentaje de adultos con IMC ≥ 30. Indicador de salud poblacional general.
Adult Smoking raw value	Número	Porcentaje de adultos que fuman actualmente. Indicador de comportamientos de riesgo.
High School Completion raw value	Número	Porcentaje de adultos ≥25 años con al menos diploma de secundaria. Proxy de capital humano y acceso a información de salud.

Resumen de Tipos de Datos y Transformaciones Requeridas

Tipo de Dato	Descripción	Transformación en Python	Datasets
Categorico nominal	Valores discretos sin orden (Hospital Type, Estado)	pd.get_dummies() / One-Hot Encoding	D1, D2, D3
Binario	Solo dos valores (Yes/No, 0/1)	map({"Yes":1,"No":0})	D1
Numérico continuo	Valores reales (ERR, porcentajes, ingresos)	pd.to_numeric(errors="coerce")	D1-D4
Numérico entero	Conteos (n° altas, n° encuestas)	pd.to_numeric(errors="coerce").astype("Int64")	D2, D3
Fecha	Fechas en formato MM/DD/YYYY	pd.to_datetime(format="%m/%d/%Y")	D2, D3
Texto libre	Nombres, direcciones	str.strip().str.upper() para joins	D1-D4
String-nulo disfrazado	"Not Available", "Not Applicable", "*", "Too Few to Report"	df.replace([...], np.nan)	D1-D3
Código geográfico	FIPS (5 dígitos con cero inicial)	dtype=str al cargar con pd.read_csv()	D1, D4

Variables Derivadas (Feature Engineering)

Variable	Fórmula / Lógica	Rango	Interpretación
HQI (Hospital Quality Index)	$0.4 \times \text{satisfacción_norm} + 0.4 \times \text{ERR_inv_norm} + 0.2 \times \text{rating_norm}$ Donde $\text{ERR_inv_norm} = 1 - \text{MinMaxScaler(ERR)}$ (menor ERR = mayor calidad)	0 a 1	Índice compuesto de calidad hospitalaria. Valores altos = alta calidad. Q25 (cuartil inferior) define la clase "low_quality=1" para XGBoost.
SVI (Socioeconomic Vulnerability Index)	$0.35 \times \text{uninsured_norm} + 0.35 \times \text{poverty_norm} + 0.30 \times (1 - \text{pcp_norm})$ Donde pcp_norm se invierte: menos médicos = mayor vulnerabilidad	0 a 1	Índice de vulnerabilidad socioeconómica del condado. Valores altos = mayor adversidad. Se asigna a cada hospital según su condado.
satisfaccion_norm	MinMaxScaler(media de métricas HCAHPS seleccionadas)	0 a 1	Componente de satisfacción del paciente normalizada.
ERR_inv_norm	$1 - \text{MinMaxScaler(Excess Readmission Ratio promedio por hospital)}$	0 a 1	ERR invertida: mayor valor = mejor desempeño en readmisiones.
rating_norm	$(\text{Hospital overall rating} - 1) / 4$	0 a 1	Rating CMS normalizado al rango [0,1].
PatientVolume	pd.cut(total_discharges, bins=[0,500,2000,∞], labels=["Bajo","Medio","Alto"])	Bajo/Medio/Alto	Volumen de pacientes. Los hospitales de bajo volumen tienen tasas estadísticamente inestables.
RuralFlag	1 si Hospital Type == "Critical Access Hospitals", 0 en caso contrario	0 / 1	Indicador de hospital rural/crítico. Suelen tener menor HQI por recursos limitados.
low_quality	1 si $\text{HQI} \leq \text{Q25(HQI)}$, 0 en caso contrario	0 / 1	Variable objetivo para XGBoost. Define el 25% de hospitales con peor calidad.